NOTATKI NUMERKI REMASTER

WYKŁAD 1 - WSTĘP

- Komputer w określonych sytuacjach może zwracać błędne wyniki obliczeń
- Wyniki w zależności od zadania jak i sposobu obliczeń mogą znacząco odbiegać od matematycznie poprawnych
- Można kontrolnie sprawdzić do jakich wartości powinien zbiegać wynik poprzez wyliczenie granicy dla $x \to 0$
- Przekształcenie rozwiązywanego działania może spowodować zmianę dokładności wyniku zwracanego przez komputer
- Rozpisanie w szereg, często może poprawić dokładność obliczeń. Można szacować ile wyrazów szeregu jest potrzebne do uzyskania zadanej precyzji

WYKŁAD 2 - ARYTMETYKA ZMIENNOPOZYCYJNA

Rodzaje błędów

x - wynik dokładny

$\tilde{x}$ - wynik przybliżony

$|x - \tilde{x}|$ - błąd bezwzględny

$\left|\frac{x - \tilde{x}}{x}\right|$ - błąd względny (lepszy)

Reprezentacja liczb rzeczywistych w komputerze

Dla $x \in \mathbb{R} / \{0\}$

$$x = s \cdot m \cdot 2^{c}$$

$s \in \{+1, -1\}$ znak

$m \in [\frac{1}{2}, 1)$ mantysa

$c \in \mathbb{Z}$ cecha

Taka reprezentacja jest jednoznaczna

Reprezentacja mantysy

$$m = \sum_{i=1}^{\infty} c_{-i} 2^{-i} \qquad c_i \in \{0,1\} \quad c_{-1} = 1$$

Takie rozwinięcie jest nieskończone, więc stosujemy zaokrąglenia:

- obcięcie $m_+^c = \sum_{i=1}^{+} c_{-i} 2^{-i}$ (ucinamy resztę bitów)
- zaokrąglenie symetryczne $m_+^r = \sum_{i=1}^{+} c_{-i} 2^{-i} + \boxed{c_{-(+1)} \cdot 2^{-+}}$

uwzględniamy dodatkowo jeden bit

$$|m - m_+^c| \leq 1 \cdot 2^{-+}$$
$$|m - m_+^r| \leq \frac{1}{2} \cdot 2^{-+}$$

+ - liczba bitów mantysy

Reprezentacja zmiennopozycyjnej liczby rzeczywistej

$$x \approx choop(x) = s \cdot m_+^c \cdot 2^c \qquad \left|\frac{choop(x) - x}{x}\right| \leq 2 \cdot 2^{-+}$$
$$x \approx rd(x) = s \cdot m_+^r \cdot 2^c \qquad \left|\frac{rd(x) - x}{x}\right| \leq 2^{-+}$$

Zakres reprezentacji liczb

$$x \in (-2^{c_{max}}, 2^{c_{max}})$$

maksymalna cecha

Możemy zaprezentować jedynie dyskretny podzbiór

Zmiennopozycyjna realizacja działań arytmetycznych

$$fl(x \circ y) = (x \circ y)(1 + \varepsilon_{x,y,\circ}) \qquad |\varepsilon_{x,y,\circ}| \leq 2^{-+}$$

błąd względny

Twierdzenie o kumulacji błędów

Dla $|\delta_i| \leq 2^{-+}$ $\quad 1 + E = \prod_{i=1}^{n} (1 + \delta_i) \Rightarrow |E| \lesssim n \cdot 2^{-+}$

Zjawisko utraty cyfr znaczących

Dla $x, y \in X_{fl}$ $\quad x > y > 0$, $x \approx y$ bliskie sobie liczby.

Przy ich odejmowaniu $x - y$, zostaje reszta spoza zakresu mantysy, więc komputer może zachować się nieprzewidywalnie.

Przykład wyliczania błędu

Obliczanie sumy czterech liczb, P to program

$$fl(P) = ((((x_1+x_2)(1+\varepsilon_2)+x_3)(1+\varepsilon_3)+x_4)(1+\varepsilon_4) =$$
$$= x_1(1+\varepsilon_2)(1+\varepsilon_3)(1+\varepsilon_4) +$$
$$x_2(1+\varepsilon_2)(1+\varepsilon_3)(1+\varepsilon_4) +$$
$$x_3(1+\varepsilon_3)(1+\varepsilon_4) +$$
$$x_4(1+\varepsilon_4) =$$
$$= x_1(1+E_1) + x_2(1+E_2) + x_3(1+E_3) + x_4(1+E_4) = \sum_{i=1}^{4} x_i(1+E_i)$$

$|E_1| \leq 3\cdot 2^{-+}$ $|E_2| \leq 3\cdot 2^{-+}$ $|E_3| \leq 2\cdot 2^{-+}$ $|E_4| \leq 2^{-+}$

Z twierdzenia o kumulacji błędów

$$\left|\frac{S - fl(P)}{S}\right| = \left|\frac{\sum_{i=1}^{4} x_i - \sum_{i=1}^{4} x_i(1+E_i)}{\sum_{i=1}^{4} x_i}\right| = \left|\frac{\sum_{i=1}^{4} x_i E_i}{\sum_{i=1}^{4} x_i}\right| \overset{**}{=} \frac{\left|\sum_{i=1}^{4} x_i E_i\right|}{\left|\sum_{i=1}^{4} x_i\right|} \overset{*}{\leq}$$

$$\overset{*}{\leq} \frac{\sum_{i=1}^{4} |x_i||E_i|}{\left|\sum_{i=1}^{4} x_i\right|} \leq \frac{\sum_{i=1}^{4} |x_i|}{\left|\sum_{i=1}^{4} x_i\right|} \cdot (3\cdot 2^{-+}) = \underbrace{k\cdot 3}_{\text{dowolnie duże}} \cdot 2^{-+}$$

bo $|E_i| \leq 3\cdot 2^{-+}$

WYKŁAD 3 - UWARUNKOWANIE ZADANIA I NUMERYCZNA POPRAWNOŚĆ

Definicja uwarunkowania zadania

Zadanie jest źle uwarunkowane jeśli mała względna zmiana danych powoduje dużą względną zmianę wyniku.

Przykłady źle uwarunkowanych:

- Wielomian Wilkinsona $w(x) = \prod_{i=1}^{20}(x-i)$ (efekt motyla)
- Macierz Hilberta $H_{ij} = \frac{1}{i+j-1}$ $\det(H) = ?$ (błąd prawie 100%)

Wskaźnik uwarunkowania zadania

Wielkość mówiąca o tym jak względna zmiana danych wpływa na względną zmianę wyniku.

Przyjmujemy, że jeżeli wskaźnik jest ograniczony to zadanie jest dobrze uwarunkowane.

Przykład wskaźnika dla funkcji jednoargumentowych

$$\left|\frac{f(x)-f(x+h)}{f(x)}\right| = \left|\frac{f(x+h)-f(x)}{h}\right| \cdot \frac{|h|}{|f(x)|} \overset{\text{mało } h}{\approx} |f'(x)| \cdot \left|\frac{h}{f(x)}\right| = \left|\frac{x f'(x)}{f(x)}\right| \left|\frac{h}{x}\right|$$

- $\left|\frac{f(x)-f(x+h)}{f(x)}\right|$ – względna zmiana wartości funkcji przy zmianie argumentu
- $\left|\frac{f(x+h)-f(x)}{h}\right|$ – potraktowanie jako pochodna przy $h \to 0$
- $\left|\frac{x f'(x)}{f(x)}\right|$ – WSKAŹNIK
- $\left|\frac{h}{x}\right|$ – względna zmiana danych

$$f'(x) = \lim_{h\to 0} \frac{f(x+h)-f(x)}{h}$$

z def pochodnej

Definicja algorytmu numerycznie poprawnego

Algorytm jest numerycznie poprawny, jeśli wynik jego działania w arytmetyce zmiennopozycyjnej, może być zinterpretowany jako mało zaburzony wynik dokładny dla mało zaburzonych danych

$$\underbrace{fl(A(a,b))}_{\text{obliczanie } A \text{ na podstawie danych } a \text{ i } b \text{ w arytmetyce zmiennopozycyjnej}} = \underbrace{A(a(1+\varepsilon), b(1+\delta))}_{\text{wynik dokładny dla mało zaburzonych danych}} \cdot \underbrace{(1+\gamma)}_{\text{małe zaburzenie wyniku}}$$

$|\varepsilon|, |\delta|, |\gamma| \leq k \cdot 2^{-t}$ bo algorytm jest numerycznie poprawny

UWAGA!

Jeżeli algorytmem numerycznie poprawnym rozwiązujemy źle uwarunkowane zadanie to dalej jest źle!

WYKŁ

Postaci wi

- naturalna
- Newtona

zapisując : w dokładniej

$x_0 \vdots \ldots x_n$

$a_0 \ldots a_n$

Schemat

$w_n = a_n$

Uogólniony

$w_n = a_n$

Wielomiany

$T_0(x) = 1$

własności

- $T_k \in$
- $T_k(x)$
- $T_k(-x) =$
- $x \in [-$
- LINEŁ
- miejsca
- $|T_k(x)$

WYKŁAD 4 - ROZWIĄZYWANIE RÓWNAŃ NIELINIOWYCH

Problem zadania

Dla danej funkcji: $f: \mathbb{R} \to \mathbb{R}$ chcemy znaleźć α, $f(\alpha) = 0$
Rozwiązanie analityczne często nie jest możliwe, więc stosujemy metody przybliżające.

Metoda bisekcji

Założenia:

- f jest ciągła na przedziale (a_0, b_0)
- istnieje dokładnie jedno miejsce zerowe $\alpha \in (a_0, b_0)$
- $f(a_0) f(b_0) < 0$ (są różnych znaków)

Konstrukcja:

- wyznaczamy środek przedziału $m_{k+1} = \frac{a_k + b_k}{2}$
- jeśli $f(m_{k+1}) \approx 0$, to $\alpha = m_{k+1}$ (osiągnięto pożądaną dokładność)
- $[a_{k+1}, b_{k+1}] = \begin{cases} [a_k, m_{k+1}] : f(a_k) f(m_{k+1}) < 0 \\ [m_{k+1}, b_k] : f(b_k) f(m_{k+1}) < 0 \end{cases}$

Powtarzamy dla $k = 0 \ldots$ aż do uzyskania pożądanej dokładności.

Obserwacje:

- $|[a_k, b_k]| = \frac{b_0 - a_0}{2^k} \xrightarrow[k \to \infty]{} 0$
- Dla spełnionych założeń metoda jest zbieżna i niezawodna
- Aby otrzymać przedział długości $\leq 2\varepsilon$ (ε wtedy to błąd) wystarczy wykonać $N = \lceil \log_2 \left(\frac{b_0 - a_0}{2\varepsilon} \right) \rceil$ kroków

Metoda

Wybieramy

Intuicyjnie

punkcie

Obserwacj

- jest s
- jest za
- trzeba

Metoda

Odpowie

Startowe

$x_{n+1} =$

Analogic

Newtona

Obserwac

- wolnie
- jest
- nie t

Warunk

Z racji

stosujem

- mate
- mały
- ogran

Metoda Newtona

Wybieramy punkt startowy x_0 i iterujemy $x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$

Intuicyjnie działa to jak rysowanie stycznych do f w punkcie x_n i ustalanie x_{n+1} jako jej przecięcie z OX.

Obserwacje:
- jest szybka, ma zbieżność kwadratową
- jest zależna od doboru punktu x_0
- trzeba znać pochodną

Metoda siecznych

Odpowiednik metody Newtona, ale mający dwa punkty startowe i nie wymagający liczenia pochodnej.

$x_{n+1} = x_n - \frac{f(x_n)(x_n - x_{n-1})}{f(x_n) - f(x_{n-1})}$ Pamiętamy dwa ostatnie kroki

Analogicznie do wykorzystywania stycznych w metodzie Newtona, tutaj wykorzystujemy sieczne w punktach x_n, x_{n-1}.

Obserwacje:
- wolniejsza od metody Newtona, ale nadal szybka
- jest zależna od doboru x_0, x_1
- nie trzeba znać pochodnej

Warunki stopu

Z racji tego, że nie liczymy idealnego α, $f(\alpha) = 0$, stosujemy kryteria przybliżone do warunku stopu:
- małe $|f(x_n)|$
- mały krok iteracyjny $\left|\frac{x_n - x_{n-1}}{x_n}\right|$ małe
- ograniczenie liczby iteracji: $n \leq N_{max}$

Wykładnik zbieżności (rząd metody)

Niech $x_n \to \alpha$. Ciąg $x_0, \dots, x_n$ ma asymptotyczny rząd zbieżności p jeśli istnieje $C > 0$: $p \geq 1$ takie, że:

$$\lim_{n\to\infty} \frac{|x_{n+1} - \alpha|}{|x_n - \alpha|^p} = C$$

$|x_{n+1} - \alpha|$ ← błąd następnego kroku

C ← stała asymptotyczna

$|x_n - \alpha|^p$ ← błąd poprzedniego kroku podniesiony do potęgi p

przypadki szczególne:

- $p = 1$, $C \in (0,1)$ zbieżność liniowa
- $p = 2$ zbieżność kwadratowa
- $p = 3$ zbieżność sześcienna

Im wyższe p, tym metoda zbiega szybciej (lepiej).

Metody jednokrokowe (dowodzenie wykładnika)

Dla danych x_0, F, gdzie $x_{n+1} = F(x_n)$, $x_n \to \alpha$, $f(\alpha) = 0$

p jest rzędem metody $\iff$

$$\begin{cases} F(\alpha) = \alpha \\ F'(\alpha) = F''(\alpha) = \dots = F^{(p-1)}(\alpha) = 0 \\ F^{(p)}(\alpha) \neq 0 \end{cases}$$

wszystkie pochodne aż do p dają 0 w punkcie α, dla p-ta pochodna już nie

Dodatkowo stała asymptotyczna to:

$$C = \frac{|F^{(p)}(\alpha)|}{p!}$$

ych

$\frac{x f'(x)}{f(x)}$ | $\frac{h}{x}$

względna zmiana danych

ałania

jako

ych danych

e poprawny

y

WYKŁAD 5 - INTERPOLACJA WIELOMIANOWA

Postaci wielomianów

- naturalna $\omega(x) = \sum_{i=0}^{n} a_i x^i$
- Newtona $\omega(x) = \sum_{i=0}^{n} a_i p_i(x)$, gdzie

$$p_0(x) = 1 \qquad p_k(x) = \prod_{i=0}^{k-1} (x - x_i)$$

zapisując dokładniej: $\omega(x) = a_0 + a_1(x-x_0) + a_2(x-x_0)(x-x_1) + \ldots + a_n(x-x_0)\ldots(x-x_{n-1})$

$x_0 \ldots x_{n-1}$ to ustalone parametry

$a_0 \ldots a_n$ to współczynniki

Schemat Hornera (postać naturalna)

$\omega_n = a_n \qquad \omega_k = \omega_{k+1} \cdot x + a_k \qquad \omega(x) = \omega_0$

Uogólniony schemat Hornera (postać Newtona)

$\omega_n = a_n \qquad \omega_k = \omega_{k+1}(x - x_i) + a_k \qquad \omega(x) = \omega_0$

Wielomiany Czebyszewa

$T_0(x) = 1 \qquad T_1(x) = x \qquad T_k(x) = 2x \cdot T_{k-1}(x) - T_{k-2}(x)$

własności:

- $T_k \in \Pi_k / \Pi_{k-1}$ (ma stopień k)
- $T_k(x) = 2^{k-1} x^k + 0 \cdot x^{k-1} + \ldots$ (w postaci potęgowej mają symetryczne współczynniki)
- $T_k(-x) = (-1)^k \cdot T_k(x)$
- $x \in [-1,1] \Rightarrow T_k(x) = \cos(k \cdot \arccos(x))$
- $LIN\{T_0, T_1 \ldots T_n\} = \Pi_n$
- miejsca zerowe T_k są rzeczywiste, pojedyncze i leżą w $(-1,1)$
- $|T_k(x)| \leq 1$ dla $x \in [-1,1]$

Postać Clenshawa (nie mylić z wielomianami składowymi T_k)

$$w(x) = \sum_{k=0}^{n}{}' a_i T_i(x) = \frac{1}{2}a_0 T_0(x) + a_1 T_1(x) + \ldots + a_n T_n(x)$$

oznacza, że pierwszy element sumy jest dzielony przez 2

Algorytm Clenshawa (obliczanie wartości wielomianu w postaci Clenshawa)

$w_{n+2} = w_{n+1} = 0 \quad w_k = 2x \cdot w_{k+1} - w_{k+2} + a_k \quad w(x) = \frac{w_0 - w_2}{2}$

Zadanie interpolacyjne Lagrange'a

Mamy:

- $x_0 \ldots x_n \in \mathbb{R}$ węzły interpolacji (parami różne)
- $y_0 \ldots y_n \in \mathbb{R}$ wartości w węzłach

Szukamy $L_n \in \Pi_n$, taki że $L_n(x_k) = y_k$ dla wszystkich węzłów

To zadanie zawsze ma jedno rozwiązanie!

$$L_n(x) = \sum_{k=0}^{n} \lambda_k(x) \cdot y_k \quad \text{gdzie} \quad \lambda_k(x) = \prod_{\substack{i=0 \\ i \neq k}}^{n} \frac{x - x_i}{x_k - x_i} \quad \lambda_k(x_i) = \begin{cases} 1 : k = i \\ 0 : k \neq i \end{cases}$$

WYKŁAD 6 - OPTYMALIZACJA INTERPOLACJI

Definicja ilorazów różnicowych

Ilorazem różnicowym funkcji $f(x_k) = y_k$ w węzłach $x_i \ldots x_k$ jest

$$f[x_i, \ldots, x_k] = \frac{f[x_{i+1}, \ldots, x_k] - f[x_i, \ldots, x_{k-1}]}{x_k - x_i} \qquad f[x_i] = f(x_i) = y_i$$

Postać Newtona wielomianu różnicowego

$$L_n(x) = \sum_{k=0}^{n} f[x_0, \ldots, x_k] p_k(x) \qquad p_k(x) = \prod_{i=0}^{k-1} (x - x_k)$$

$$L_{n+1}(x) = L_n(x) + \underbrace{f[x_0, \ldots, x_{n+1}]}_{\text{mając wyliczone ilorazy zajmuje czas liniowy}} p_{n+1}(x)$$

obliczanie dodanie elementu wyliczenie wartości

Właściwości

- Ilorazy r
- Łatwo d
- Mając w stosując
- Zaleca s
- Algorytm

Błąd inte

$(a,b) \supset \xi$

$\max_{x \in (a,b)} |f($

Optymalny

dla [a

miejsca

$x_k = \cos$

Dla [a

Własności postaci Newtona wielomianu interpolacyjnego

- Ilorazy różnicowe można obliczyć „tablicowo" w $O(n^2)$
- Łatwo dodać kolejne obserwacje w $O(n)$
- Mając wyliczone ilorazy, wartość $L_n(x)$ obliczamy w $O(n)$ stosując uogólniony schemat Hornera
- Zaleca się sortowanie węzłów ze względów numerycznych
- Algorytm nie jest numerycznie poprawny (zawodzi dla $n \geq 30$)

Błąd interpolacji

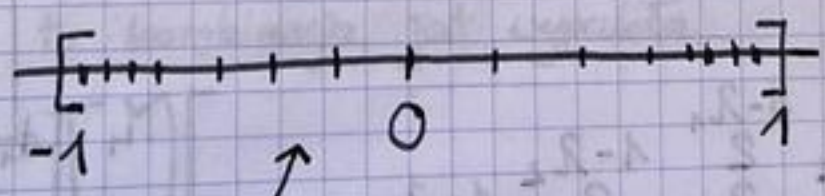
$(a,b) \supset \{x_0, \dots, x_n\}$

$$\max_{x\in(a,b)} |f(x) - L_n(x)| \leq \underbrace{\max_{x\in(a,b)} \left|\frac{f^{(n+1)}(x)}{(n+1)!}\right|}_{\text{nic mamy wpływu}} \cdot \max_{x\in(a,b)} \underbrace{|(x-x_0)\dots(x-x_n)|}_{\text{można optymalizować}}$$

Optymalny dobór węzłów

dla $[a,b] = [-1,1]$ za $x_0 .. x_n$ najlepiej przyjąć miejsca zerowe $(n+1)$szego wielomianu Czebyszewa:

$$x_k = \cos\left(\frac{2k+1}{2n+2} \cdot \pi\right)$$



rozkład węzłów Czebyszewa (coraz gęściej im bliżej -1 i 1)

Dla $[a,b] \neq [-1,1]$ stosujemy bijekcję z $[-1,1]$ w $[a,b]$.

WYKŁAD 7 - NIFS 3

Naturalna interpolacyjna funkcja sklejana 3 stopnia

- $s(t_k) = y_k$ (węzły)
- $s \in \Pi_3$ dla każdego $[t_{k-1}, t_k]$
- s, s', s'' są ciągłe na $[a, b]$
- $s''(a) = s''(b) = 0$ (naturalność) (po to, żeby była jednoznaczność)

Efektywne doliczanie

Istnieje wzór na $s(t)$, ale jest długi i zakazany na AN.

Inna metoda:

Zdefiniujmy „momenty":

$M_k = s''(t_k)$

spełniają one:

$\lambda_k M_{k-1} + 2M_k + (1-\lambda_k) M_{k+1} = 6d_k$

$$\lambda_k = \frac{h_k}{h_k + h_{k+1}} \qquad h_k = t_k - t_{k-1}$$

$$d_k = f[t_{k-1}, t_k, t_{k+1}]$$

$$\begin{bmatrix} 2 & 1-\lambda_1 & & & \\ \lambda_2 & 2 & 1-\lambda_2 & & \\ & \lambda_3 & 2 & 1-\lambda_3 & \\ & & \ddots & \ddots & \ddots \\ & & & \lambda_{n-2} \; 2 & 1-\lambda_{n-2} \\ & & & & \lambda_{n-1} \; 2 \end{bmatrix} \begin{bmatrix} M_1 \\ \vdots \\ M_{n-1} \end{bmatrix} \begin{bmatrix} d_1 \\ \vdots \\ d_{n-1} \end{bmatrix}$$

Układ jest trójpaskątnieczy, więc można go rozwiązać w $O(n)$

Algorytm wyliczania:

- $q_0 = u_0 = 0$
- $p_k = \lambda_k q_{k-1} + 2$
- $q_k = (\lambda_k - 1)/p_k$
- $u_k = (d_k - \lambda_k u_{k-1})/p_k$

$M_{n-1} = u_{n-1} \qquad M_k = u_k + q_k M_{k+1}$

Kawałek para

$\gamma(t) = [$

Te funkcje

WYKŁ

Wektory a

$\mathbb{R}^d$ - wekto

$\mathbb{E}^d$ - punk

To nie

Kombinacja

Dla punkt

kombinacja

Jeżeli wsz

Wielomiany

$B_k^n(t) = ($

własności:

- $B_k^n(t) \geq$
- B_k^n ma
- $B_k^n(t) =$
- $B_k^n(t) =$
- $(B_k^n(t))' =$
- $\sum_{i=0}^{n} B_i^n(t)$
- $B_0^n, B_1^n,$

Krzywe parametryczne

$\gamma(t) = [(x(t), y(t)) : a \leq t \leq b]$ $\quad x, y : [a,b] \to \mathbb{R}$

funkcje opisujące położenie względem czasu

Te funkcje można przybliżać za pomocą NURBS

WYKŁAD 8 - KRZYWE BEZIERA

Wektory a punkty

$\mathbb{R}^d$ - wektory d-wymiarowe

$\mathbb{E}^d$ - punkty d-wymiarowe

To nie to samo!

Kombinacja barocentryczna punktów

Dla punktów $w_i \in \mathbb{E}^d$ oraz skalarów $\alpha_i \in \mathbb{R}$ $\sum_{i=0}^{n} \alpha_i = 1$

kombinacja barocentryczna to $\sum_{i=0}^{n} \alpha_i w_i \in \mathbb{E}^d$

Jeżeli wszystkie $\alpha_i \geq 0$ to kombinacja jest wypukła.

Wielomiany Bernsteina

$$B_k^n(t) = \binom{n}{k} t^k (1-t)^{n-k}$$

własności:

- $B_k^n(t) \geq 0$ dla $t \in [0,1]$
- B_k^n ma dokładnie jedno ekstremum w przedziale $[0,1]$: $t = \frac{k}{n}$
- $B_k^n(t) = (1-t) B_k^{n-1}(t) + t \cdot B_{k-1}^{n-1}(t)$
- $B_k^n(t) = 0$ dla $k > n$ lub $k < 0$
- $\left(B_k^n(t)\right)' = n\left(B_{k-1}^{n-1}(t) - B_k^{n-1}(t)\right)$
- $\sum_{i=0}^{n} B_i^n(t) = 1$
- $B_0^n, B_1^n, \ldots, B_n^n \in \Pi_n / \Pi_{n-1}$, tworzą bazę Π_n

kazdy wielomian można zapisać jako kombinacja liniowa wielomianów Bernsteina

Krzywe Beziera

$P_n : [0,1] \to \mathbb{E}^2 \quad P_n(t) = \sum_{k=0}^{n} B_k^n(t) w_k$

(n — stopień krzywej; w_k — punkty kontrolne)

własności:

- $P_n(t) \in \mathbb{E}^2$ (kombinacja barycentryczna)
- $P_n(0) = w_0$, $P_n(1) = w_n$ (zachowuje początek i koniec)
- dla $t \in [0,1]$ $P_n(t) \in \text{conv}\{w_0, \dots, w_n\}$ (otoczka wypukła)
- $P_n'(0) = n(w_1 - w_0)$, $P_n'(1) = n(w_n - w_{n-1})$

Algorytm de Casteljau (obliczanie wartości krzywej Beziera)

$w_k^{(0)} = w_k \quad w_k^{(i)} = (1-t)w_k^{(i-1)} + t \cdot w_{k+1}^{(i-1)} \quad P_n(t) = w_0^{(n)}$

Ten algorytm ma złożoność $O(n^2)$

Obliczając wartości poly użyciu schematu Homera uzyskamy $O(n)$, natomiast w praktyce n jest często niewielkie, a algorytm de Casteljau ma lepszą interpretację geometryczną: jest chętnie wykorzystywany.

WYKŁAD 9 - APROKSYMACJA ŚREDNIOKWADRATOWA

Aproksymacja

Dla danego zbioru obserwacji (punktów) staramy się dobrać „najlepiej" dopasowaną funkcję. To jak dobrze dana funkcja jest dopasowana oceniamy normą, czyli miarą „wielkości" funkcji dla danych obserwacji. Aproksymacja polega na zminimalizowaniu funkcji różnicy pomiędzy szukaną funkcją a obserwacjami (minimalizacja odległości od obserwacji)

Norma średn

$\|f\|_2 = \sqrt{\sum_{k=}^{n}}$

własności:

- $\|f\|_2 \geq 0$
- $\|\alpha f\|_2 = |$
- $\|f+g\|_2 \leq$

Odległość f

Zadanie apr

Dla ustalon

$x_0, \dots, x_n$

prostych $\mathbb{E}$,

$\|f - w^*\|_2 =$

„najlepsz

Rozwiązujemy

dla zdefini

Pochodne cz

Jest to poch

zmiennych. P

$\frac{\partial f(x,y,z)}{\partial x} = \dots$

Warunkiem

zmiennych je

$\frac{\partial f(x_0,\dots,x_n)}{\partial x_0}$

$\vdots$

$\frac{\partial f(x_0,\dots,x_n)}{\partial x_n}$

Norma średniokwadratowa

$$\|f\|_2 = \sqrt{\sum_{k=0}^{n} (f(x_k))^2}$$

własności:

- $\|f\|_2 \geq 0$, $\|f\|_2 = 0 \iff \forall_{x_k} f(x_k) = 0$
- $\|\alpha f\|_2 = |\alpha| \cdot \|f\|_2$
- $\|f+g\|_2 \leq \|f\|_2 + \|g\|_2$

Odległość funkcji f od g to $\|f-g\|_2$

Zadanie aproksymacji średniokwadratowej

Dla ustalonej funkcji f („trudnej") określonej w punktach $x_0, \dots, x_n$ (obserwacje) i dla ustalonego zbioru funkcji prostych $\mathfrak{X}$, znaleźć $\omega^* \in \mathfrak{X}$, takie że

$$\|f-\omega^*\|_2 = \min_{\omega \in \mathfrak{X}} \|f-\omega\|_2$$

ω^* — „najlepsza" z funkcji ze zbioru $\mathfrak{X}$

Rozwiązujemy to zadanie szukając ekstremum (minimum) dla zdefiniowanej normy.

Pochodne cząstkowe

Jest to pochodna po jednej zmiennej dla funkcji wielu zmiennych. Pozostałe zmienne traktujemy wtedy jako stałe, np.:

$$\frac{\partial f(x,y,z)}{\partial x} = \dots$$

Warunkiem koniecznym istnienia ekstremum funkcji wielu zmiennych jest zerowanie się wszystkich pochodnych:

$$\frac{\partial f(x_0,\dots,x_n)}{\partial x_0} = 0$$
$$\vdots$$
$$\frac{\partial f(x_0,\dots,x_n)}{\partial x_n} = 0$$

Przykładowy model

$\mathfrak{X} = \{ ax+b \,;\, a,b \in \mathbb{R} \}$

Wyznaczamy funkcję błędu (to co będziemy minimalizować):

$$E(a,b) = \sum_{k=0}^{N} \left(f(x_k) - (ax_k+b) \right)^2$$

(to jest norma, ale z pominiętym pierwiastkiem bo jest monotoniczny i nie ma znaczenia dla obliczania minimum)

Szukamy minimum:

$$\begin{cases} \frac{\partial E(a,b)}{\partial a} = 0 \Rightarrow \sum_{k=0}^{n} 2(f(x_k) - ax_k - b)(-x_k) = 0 \\ \frac{\partial E(a,b)}{\partial b} = 0 \Rightarrow \sum_{k=0}^{n} 2(f(x_k) - ax_k - b)(-1) = 0 \end{cases}$$

Dalej rozwiązujemy jak zwykły układ równań, co da nam a i b.

WYKŁAD 10 - APROKSYMACJA WIELOMIANOWA

Zadanie aproksymacji wielomianowej

Analogicznie do poprzedniego wykładu szukamy modelu, ale tym razem chodzi nam konkretnie o wielomian, przez co rozwiązanie może być bardziej efektywne.

Iloczyn skalarny funkcji

$$(f,g)_N = \sum_{k=0}^{n} f(x_k) \cdot g(x_k) \qquad (\cdot,\cdot)_N : \mathbb{F} \times \mathbb{F} \to \mathbb{R}$$

ilość obserwacji; zbiór funkcji

własności:

- $(f,f)_N \geq 0 \qquad (f,f)_N = 0 \iff \forall_{x_k} f(x_k) = 0$
- $(f,g)_N = (g,f)_N$
- $(f+g,h)_N = (f,h)_N + (g,h)_N$
- $(\alpha \cdot f, g)_N = \alpha (f,g)_N$
- $(f,f)_N = \|f\|_2^2$

Ortogonalny

Funkcje f i g
wtw. (f,g)

Układ funkcj
{ (fi, fj)
{ (fi, fi)

Ortogonalizacj

Weźmy dowo
do postaci o

$f_0 = g_0$

Ten algorytm

Zależności rek

$P_0(x) = 1$

$c_k = \frac{(xP_{k-1}, P}{(P_{k-1}, P}$

Dzięki tej
odwołując s
współczynnik

Baza ortog

Wielomiany
$\forall_{w \in \Pi_m} \exists! a_0$

Ponadto istn

Ortogonalny układ funkcji

Funkcje f i g są ortogonalne względem iloczynu skalarnego wtw. $(f,g)_N = 0$.

Układ funkcji jest ortogonalny względem $(\cdot,\cdot)_N$ wtw.

$$\begin{cases} (f_i, f_j)_N = 0 & (i \neq j) \\ (f_i, f_i)_N > 0 \end{cases}$$

Ortogonalizacja Grama-Schmidta

Weźmy dowolny układ funkcji $g_0, \dots, g_m$ i doprowadźmy go do postaci ortogonalnej $f_0, \dots, f_m$.

$$f_0 = g_0 \qquad f_k = g_k - \sum_{i=0}^{k-1} \frac{(g_k, f_i)_N}{(f_i, f_i)_N} \cdot f_i$$

Ten algorytm ma złożoność $O(Nm^2)$, co jest kosztowne.

Zależność rekurencyjna ciągu wielomianów ortogonalnych

$$P_0(x) = 1 \qquad P_1(x) = x - c_1 \qquad P_k(x) = (x - c_k)P_{k-1}(x) - d_k P_{k-2}(x)$$

$$c_k = \frac{(xP_{k-1}, P_{k-1})_N}{(P_{k-1}, P_{k-1})_N} \qquad d_k = \frac{(P_{k-1}, P_{k-1})_N}{(P_{k-2}, P_{k-2})_N}$$

Dzięki tej zależności kolejne wielomiany można budować odwołując się jedynie do 2 poprzednich, natomiast współczynniki c_k i d_k są podobne. Stąd złożoność to tylko $O(Nm)$

Baza ortogonalna wielomianów

Wielomiany ortogonalne $P_0, \dots, P_m$ tworzą bazę Π_m.

$\forall_{w \in \Pi_m} \exists!_{a_0, \dots, a_m} \; w(x) = \sum_{k=0}^{m} a_k P_k(x)$ (istnieje jednoznaczna reprezentacja w bazie)

Ponadto istnieje wzór na $a_k = \frac{(w, P_k)_N}{(P_k, P_k)_N}$

Rozwiązanie aproksymacji

Dla danej funkcji f i obserwacji $x_0, \dots, x_n$ chcemy znaleźć $w_m^* \in \Pi_m$, że $\|f - w_m^*\|_2 = \min_{w_m \in \Pi_m} \|f - w_m\|_2$.

Wielomian optymalny wyraża się wzorem:

$$w_m^*(x) = \sum_{k=0}^{m} a_k p_k(x)$$

gdzie p_k to wielomiany ortogonalne wyliczone na podstawie iloczynu skalarnego zdefiniowanego na obserwacjach:

$$(g, h)_N = \sum_{k=0}^{N} g(x_k) h(x_k)$$

Natomiast współczynniki są postaci:

$$a_k = \frac{(f, p_k)_N}{(p_k, p_k)_N}$$

Po wyznaczeniu wielomianów ortogonalnych i współczynników obliczenie $w_m^*(x)$ na podstawie danego x można łatwo zrealizować za pomocą algorytmu Clenshawa:

$$B_{m+2} = B_{m+1} = 0 \qquad B_k = a_k + (x - c_{k+1}) B_{k+1} - d_{k+2} B_{k+2}$$

Wtedy $w_m^*(x) = a_0 B_0$

Ponadto zauważmy, że zachodzi

$$w_{m+1}^*(x) = w_m^*(x) + a_{m+1} p_{m+1}(x)$$

Błąd aproksymacji

$$\|f - w_m^*\|_2 = \sqrt{\|f\|_2 - \sum_{k=0}^{m} \frac{((f, p_k)_N)^2}{(p_k, p_k)_N}}$$

WYKŁ

Całki

$$\int_a^b f(x)\,dx$$

$$\int_a^b f(x)\,dx$$

Intuicyjnie

Kwadratura

$$Q_n(f) =$$

↑ liczba

Chcemy do

$$\int_a^b f(x)\,dx \approx$$

Rząd kwad

Miara dokł
całkowania

Rząd kwad

- $\forall_{w \in \Pi_r}$
- $\exists_{v \in \Pi_r}$

Im wyższy

Ponadto

Kwadratury

$$\int_a^b f(x)\,dx \approx$$

WYKŁAD 11 - KWADRATURY

Całki

$$\int f(x)dx = F(x) \iff F'(x) = f(x)$$

$$\int_a^b f(x)\,dx = F(b) - F(a), \text{ gdzie } F' = f \text{ a } f \text{ jest ciągła na } [a,b]$$

Intuicyjnie całka oznaczona to pole pod wykresem funkcji.

Kwadratura liniowa

$$Q_n(f) = \sum_{k=0}^{n} A_k^{(n)} f(x_k^{(n)})$$

(n ↑ liczba węzłów; kombinacja liniowa wartości funkcji podcałkowej w węzłach)

Chcemy dobrać $x_0^{(n)}, \dots, x_n^{(n)}$ oraz $A_0^{(n)}, \dots, A_n^{(n)}$, żeby

$$\int_a^b f(x)dx \approx Q_n(f)$$

Rząd kwadratury liniowej

Miara określająca zdolność kwadratury do bezbłędnego całkowania wielomianów określonego stopnia.

Rząd kwadratury Q_n wynosi $r \in \mathbb{N}$ wtw.

- $\forall_{\omega \in \Pi_{r-1}} \int_a^b \omega(x)dx = Q_n(\omega)$ (przybliża wszystkie stopnia $< r$)
- $\exists_{v \in \Pi_r / \Pi_{r-1}} \int_a^b v(x)dx \neq Q_n(v)$ (istnieje wielomian stopnia r, którego już nie przybliża)

Im wyższy rząd tym lepiej.

Ponadto $\text{rząd}(Q_n) \leq 2n+2$

Kwadratury interpolacyjne

$$\int_a^b f(x)\,dx \approx \int_a^b L_n(x)\,dx$$

L_n to wielomian interpolacyjny $L_n(x_k^{(n)}) = f(x_k^{(n)})$

Postać Lagrange'a wielomianu interpolacyjnego

$$\int_a^b L_n(x)dx = \int_a^b \left(\sum_{k=0}^{n} f(x_k)\ell_k(x)\right)dx = \sum_{k=0}^{n} \underbrace{\left(\int_a^b \ell_k(x)dx\right)}_{A_k} f(x_k)$$

x_k a nie x, ponieważ mogą wystąpić węzły

Stąd $Q_n(f) = \sum_{k=0}^{n} A_k f(x_k)$ $\qquad A_k = \int_a^b \underbrace{\left(\prod_{\substack{i=0 \\ i\neq k}}^{n} \frac{x-x_i}{x_k-x_i}\right)}_{\text{wielomian stopnia } n,\ \text{istnieje algorytm na efektywne obliczanie tego}} dx$

Rząd kwadratury interpolacyjnej:
$r \in \langle n+1, 2n+2 \rangle$

Błąd kwadratury interpolacyjnej

$$f(x) - L_n(x) = \frac{f^{(n+1)}(\eta_{n+1})}{(n+1)!}(x-x_0)\cdot\ldots\cdot(x-x_n) \qquad \eta_{n+1} \in (a,b)$$

stąd:

$$\int_a^b f(x)dx - \int_a^b L_n(x)dx = \underbrace{\frac{1}{(n+1)!}\int_a^b f^{(n+1)}(\eta_{n+1})(x-x_0)\cdot\ldots\cdot(x-x_n)dx}_{\text{błąd}}$$

Kwadratury Newtona - Cotesa

~~Kwadratury oparte~~ Dobieramy węzły równoodległe:

$x_k = a + k\cdot h \qquad h = \frac{b-a}{n}$ (węzły równoodległe w $[a,b]$

wtedy:

$$A_k = \frac{(-1)^{n-k}h}{k!(n-k)!}\int_0^n \prod_{\substack{j=0 \\ j\neq k}}^{n}(t-j)\,dt$$

Oznaczamy je jako Q_n^{NC}.

- $n=1$ (wzór trapezów) $Q_1^{NC}(f) = \frac{b-a}{2}(f(a)+f(b))$

  $R_1^{NC}(f) = -\frac{(b-a)^3}{12}\cdot f''(\eta) \qquad \eta \in [a,b]$

- $n=2$ (wzór Simpsona) $Q_2^{NC}(f) = \frac{b-a}{6}\left[f(a) + 4f\left(\frac{a+b}{2}\right) + f(b)\right]$

  $R_2^{NC}(f) = -\frac{1}{90}h^5 f^{(4)}(\eta) \qquad \eta \in [a,b]$

WYKŁ

Kwadratu

Dzielimy

mato się

kwadratur

Dzielimy

$\int_a^b f(x)\,dx$

Złożony

$R_n^T(f)$

Złożony

$\int_a^b f(x)\,d$

$= \frac{h}{3}(2$

$R_n^S(f) =$

Zbieżność

$\lim_{n\to\infty} T_n$

$\lim_{n\to\infty} S_n$

WYKŁAD 12 - KWADRATURY ZŁOŻONE

Kwadratury złożone

Dzielimy przedział całkowania na części (w których funkcja mało się zmienia) i dla każdej części stosujemy prostą kwadraturę liniową.

Dzielimy na przedziały: $[t_0, t_1], [t_1, t_2], \dots, [t_{n-1}, t_n]$

$$\int_a^b f(x)\,dx = \sum_{k=0}^{n-1} \int_{t_k}^{t_{k+1}} f(x)\,dx$$

Złożony wzór trapezów

pierwszy i ostatni wyrazy sumy są dzielone przez 2

$$\int_a^b f(x)\,dx = \sum_{k=0}^{n-1} \int_{t_k}^{t_{k+1}} f(x)\,dx = \sum_{k=0}^{n-1} \frac{h}{2}[f(t_k) + f(t_{k+1})] = h \sum_{k=0}^{n}{}'' f(t_k) = T_n(f)$$

$$R_n^T(f) = -n\frac{h^3}{12} f''(\eta) \quad \eta \in [a,b]$$

Złożony wzór Simpsona

$$\int_a^b f(x)\,dx = \sum_{k=0}^{n-1} \int_{t_{2k}}^{t_{2k+2}} f(x)\,dx = \sum_{k=0}^{n-1} \frac{h}{3}[f(t_{2k}) + 4f(t_{2k+1}) + f(t_{2k+2})] =$$

$$= \frac{h}{3}\left(2\sum_{k=0}^{n}{}'' f(t_{2k}) + 4\sum_{k=1}^{n} f(t_{2k-1})\right) = S_n(f)$$

$$R_n^S(f) = (a-b)\frac{h^4}{180} f^{(4)}(\eta) \quad \eta \in [a,b]$$

Zbieżność kwadratur złożonych

$$\lim_{n\to\infty} T_n(f) = \int_a^b f(x)\,dx$$

$$\lim_{n\to\infty} S_n(f) = \int_a^b f(x)\,dx$$

równość dla $n \to \infty$ (nieskończona ilość przedziałów)

Zależność pomiędzy złożonymi wzorami trapezów i Simpsona

[redacted]

$$S_{2n}(f) = \frac{4T_{2n}(f) - T_n(f)}{4-1}$$

Metoda Romberga

$$T_{m,k} = \frac{4^m T_{m-1,k+1} - T_{m-1,k}}{4^m - 1} \qquad T_{0,k} = T_2^k$$

(T_2^k ← złożony wzór trapezów)

↑ zależność budująca kolejne elementy na bazie poprzednich

$$T_2^0(f) = T_{0,0} \searrow$$
$$T_2^1(f) = T_{0,1} \to T_{1,0} \searrow$$
$$T_2^2(f) = T_{0,2} \to T_{1,1} \to T_{2,0}$$

} budowanie tablicy Romberga

↑ coraz lepsza dokładność

Rząd kwadratury $T_{m,k}$ to $2m+2$ (bardzo dobry)

Kwadratury Gaussa

Są to zwykłe kwadratury liniowe, ale cechujące się optymalnym doborem wszystkich parametrów, przez co mają maksymalnie wysoki rząd $2n+2$, dla $[a,b] = [-1,1]$.

Współczynniki dobieramy standardowo, jak dla kwadratur interpolacyjnych:

$$A_k^{(n)} = \int_a^b \left(\prod_{\substack{i \neq k \\ i=0}}^{n} \frac{x - x_i^{(n)}}{x_k^{(i)} - x_i^{(n)}} \right) dx$$

Natomiast węzły dobieramy jako miejsca zerowe wielomianów ortogonalnych, np. Legendre'a albo Czebyszewa (dodaje się wtedy zwyczajowo ich nazwę do nazwy kwadratury, np. „kwadratura Gaussa - Legendre'a").

Wielomiany L

$P_0(x) = 1$ $P_1($

Ta rekurencja

jawnych wzo

jednak zaw

współczynniki

dokładnością

programie i

WYKŁ

Układy trój

- dolnotrójk

$x_i = \frac{b_i}{}$

- górnotrójka

$x_i = \frac{b_i -}{}$

Rozwiązywan

Metoda fa

Wcześniej od

Rozwiązujemy

Zamiast pełn

Koszt: $O(n^3$

Simpsona

Wielomiany Legendre'a

$$P_0(x)=1 \quad P_1(x)=x \quad P_n(x)=\frac{2n-1}{n}\times P_{n-1}(x)-\frac{n-1}{n}P_{n-2}(x)$$

Ta rekurencja pozwala je wyznaczyć, ale nie ma jawnych wzorów na ich miejsca zerowe. W praktyce jednak zarówno miejsca zerowe oraz odpowiadające im współczynniki zostały już wielokrotnie obliczone z dużą dokładnością. Dzięki temu można je stablicować w programie i bardzo szybko obliczać kwadratury Gaussa.

WYKŁAD 13 - ALGEBRA LINIOWA

Układy trójkątne

- dolnotrójkątny $Lx=b \quad L=[l_{ij}], l_{ij}=0$ dla $j>i$

$$x_i=\frac{b_i-\sum_{j=1}^{i-1} l_{ij}x_j}{l_{ii}}$$ (podstawienie w przód)

- górnotrójkątny $Ux=b \quad U=[u_{ij}], u_{ij}=0$ dla $j<i$

$$x_i=\frac{b_i-\sum_{j=i+1}^{n} u_{ij}x_j}{u_{ii}}$$ (podstawienie wstecz)

Rozwiązywanie układów tymi sposobami ma koszt $O(n^2)$

Metoda faktoryzacji LU

Weźmy odwracalne $A=LU$ wtedy $Ax=b \Leftrightarrow (LU)x=b \Leftrightarrow L(Ux)=b$

Rozwiązujemy wtedy $\begin{cases} Ly=b \\ Ux=y \end{cases}$

Zamiast pełnego układu rozwiązujemy dwa układy trójkątne.

Koszt: $O(n^3)$ (wyznaczenie LU) $+ O(n^2) + O(n^2)$

Wyznaczanie rozkładu LU

Jeśli wszystkie minory główne wiodące są niezerowe to istnieje dokładnie jeden rozkład LU.

$$\det \underbrace{\begin{bmatrix} a_{11} & \cdots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{k1} & \cdots & a_{kk} \end{bmatrix}}_{\text{minor}} \neq 0 \quad \text{dla } k = 1, \dots, n$$

Współczynniki wyznaczamy rekurencyjnie:

- $u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj} \quad i \leq j$
- $l_{ij} = \frac{a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj}}{u_{jj}} \quad i > j$

Zastosowania rozkładu LU

- $\det(A) = \det(L)\det(U) = 1 \cdot \det(U) = u_{11} u_{12} \cdot \dots \cdot u_{nn}$
  bo L ma jedynki na przekątnej
- $A^{-1} = (LU)^{-1} = U^{-1} L^{-1}$ (rozwiązanie dwóch układów z trójkątnych)

WYKŁAD 14 - NUMERYCZNA ELIMINACJA GAUSSA

Odwracanie macierzy przez układy z wektorami bazowymi

Szukamy $A^{-1} = X = [x_1, \dots, x_n]$

Wiemy, że $AX = I_n = [e_1, \dots, e_n]$

Stąd $Ax_1 = e_1, \dots, Ax_n = e_n$

Rozwiązujemy: $Ly_k = e_k$, $Ux_k = y_k$ dla każdego k

Koszt: $O(n^3) + n \cdot O(n^2)$

Eliminacja

Weźmy A

Tworzymy k

$A^{(r)} x = b^{(r)}$

$a_{ij}^{(r)} = a_{ij}^{(r-1)}$ +

gdzie $m_{i,}$

Po n kroka

Taki układ

$x_r = \frac{b_r^{(n)} - \sum_{i=r+1}^{n}}{a_{rr}^{(}}$

Pivoting

Podczas elimin

pomimo istnie

numeryczne).

$a_{rr}^{(r)}$ na naj

- zamiane w
- pełny wybór

Rozkład z P

Eliminację Ga

macierz permutacj
wierszy A, mówi
zamianie wierszy
(partial pivoting)

rozkładana ma

Eliminacja Gaussa

Weźmy $A^{(1)}x = b^{(1)}$, gdzie $A^{(1)} = A$, $b^{(1)} = b$

Tworzymy kolejne układy (coraz bliższe trójkątnemu):

$A^{(r)}x = b^{(r)}$

$$a_{ij}^{(r)} = a_{ij}^{(r-1)} + m_{i,r-1}\, a_{r-1,j}^{(r-1)} \qquad b_i^{(r)} = b_i^{(r-1)} + m_{i,r-1}\, b_{r-1}^{(r-1)}$$

gdzie $m_{i,r-1} = -\dfrac{a_{i,r-1}^{(r-1)}}{a_{r-1,r-1}^{(r-1)}}$

Po n krokach otrzymujemy układ górnytrójkątny ($O(n^3)$)

Taki układ rozwiązujemy ($O(n^2)$)

$$x_r = \frac{b_r^{(n)} - \sum_{j=r+1}^{n} a_{rj}^{(n)} x_j}{a_{rr}^{(r)}}$$

Pivoting

Podczas eliminacji Gaussa może się zdarzyć, że $a_{rr}^{(r)} = 0$ pomimo istnienia jednoznacznego rozwiązania (problemy numeryczne). Stąd stosujemy pivoting, czyli podmianę $a_{rr}^{(r)}$ na największą możliwą wartość poprzez:

- zamianę wierszy (partial pivoting)
- pełny wybór, zamiana wierszy i kolumn (full pivoting)

Rozkład z permutacją

Eliminację Gaussa można zapisać skrótowo algebraicznie:

$$PA = LU$$

- P — macierz permutacji wierszy A, mówi o zamianie wierszy (partial pivoting)
- L — mnożniki wykorzystane do zerowania elementów
- U — końcowa macierz wynikowa eliminacji Gaussa
- A — rozkładana macierz